# DataKnow

*Prueba Técnica - Data Scientist*

**Estimación y pronóstico del costo de equipos críticos a partir de materias primas**

*Nombre*

**José Gerardo Martínez Celaya**

*Caso de Negocio*

**Gestión de Costos Operativos en un Proyecto de Construcción**

DataKnow

# ÍNDICE

**Resumen** ..... **5**
**1. Explicación del caso** ..... **5**
**2. Supuestos** ..... **6**
**3. Formas para resolver el caso y opción tomada** ..... **6**
**4. Resultados del análisis de los datos y los modelos** ..... **7**
4.1 Calidad de los datos ..... 7
4.2 ¿Qué materias primas son X, Y y Z? ..... 7
4.3 Relación entre materias primas y equipos ..... 8
4.4 Estabilidad y validación fuera de muestra ..... 8
4.5 Diagnóstico de residuos ..... 10
**5. Proyección de costos y horizonte de predicción** ..... **10**
5.1 Selección del modelo de pronóstico ..... 10
5.2 Incertidumbre: simulación Monte Carlo calibrada ..... 11
5.3 Validación con datos posteriores al corte (2023-2024) ..... 11
5.4 Horizonte de predicción ..... 12
5.5 Del pronóstico al presupuesto ..... 12
5.6 Escenarios de estrés ..... 13
**6. Presentación de resultados en un agente de IA** ..... **13**
6.1 Sistema de IA convencional frente a agente de IA ..... 13
6.2 Diseño del agente ..... 14
**7. Arquitectura propuesta en la nube (Azure)** ..... **16**
**8. Futuros ajustes o mejoras** ..... **17**
**9. Apreciaciones y comentarios del caso** ..... **18**
**Referencias** ..... **19**

## LISTA DE FIGURAS

**Figura 1.** *La serie Y pasa de precio semanal a diario a mediados de 2017* ..... 7
**Figura 2.** *Participación de cada materia prima en el precio de cada equipo* ..... 8
**Figura 3.** *Pesos estimados en ventanas móviles de 36 meses* ..... 9
**Figura 4.** *Precio real vs. predicho con pesos entrenados en 2010-2019* ..... 9
**Figura 5.** *Proyección a 12 meses del costo de cada equipo con bandas de probabilidad* ..... 11
**Figura 6.** *Precio real de X después del corte frente a la banda pronosticada* ..... 12
**Figura 7.** *Error esperado de cada equipo según los meses de anticipación* ..... 12
**Figura 8.** *El agente combina el pronóstico con noticias actuales del mercado* ..... 15
**Figura 9.** *Traza auditable de las herramientas usadas por el agente* ..... 16
**Figura 10.** *Arquitectura propuesta en Azure* ..... 17

## LISTA DE TABLAS

**Tabla 1.** *Alternativas de solución evaluadas y opción tomada* ..... 6
**Tabla 2.** *Pesos estimados de cada materia prima (mínimos cuadrados no negativos, datos diarios 2010-2023)* ..... 8
**Tabla 3.** *Días con cambios mayores a ~10% en el precio de un equipo y cambio de las materias primas el mismo día* ..... 9
**Tabla 4.** *Error absoluto porcentual medio (%) del backtest 2016-2023, por insumo y horizonte (meses)* ..... 10
**Tabla 5.** *Precio unitario proyectado por mes y reserva de contingencia (horizonte recomendado de 6 meses)* ..... 13
**Tabla 6.** *Impacto de choques en las materias primas sobre el precio de los equipos (base: ago-2023)* ..... 13
**Tabla 7.** *Conceptos de un agente de IA y cómo se implementan en esta solución* ..... 14
**Tabla 8.** *Componentes de la arquitectura y su función* ..... 17

**Glosario de términos**

**Agente de IA:** sistema que, a partir de un objetivo, decide qué herramientas usar (consultar el pronóstico, buscar noticias, calcular escenarios) y ejecuta acciones; a diferencia de un modelo convencional, no solo predice.

**Backtest de origen móvil:** simulación en la que, mes a mes, se entrena solo con la historia disponible hasta ese momento y se compara el pronóstico con lo que realmente ocurrió.

**Caminata aleatoria:** serie en la que cada valor es el anterior más un cambio impredecible; su mejor pronóstico es el último valor observado.

**Cointegración:** relación de largo plazo entre series no estacionarias cuya diferencia sí es estacionaria; descarta que la relación sea espuria.

**Dickey-Fuller aumentada (ADF):** prueba de raíz unitaria; con $p < 0.05$ se concluye que la serie es estacionaria.

**Elasticidad:** cambio porcentual del precio de un equipo cuando una materia prima sube 1%.

**Estacionariedad:** propiedad de una serie que regresa a un nivel estable, con media y varianza constantes en el tiempo.

**Lasso:** regresión que penaliza el tamaño de los coeficientes y lleva a cero los de las variables que no aportan.

**Ljung-Box:** prueba conjunta de autocorrelación; con $p > 0.05$ el residuo se considera ruido blanco.

**MAPE:** error absoluto porcentual medio: promedio de |real - pronóstico| / real.

**Monte Carlo:** simulación de miles de futuros posibles para medir la incertidumbre del pronóstico.

**NNLS:** mínimos cuadrados no negativos: regresión cuyos coeficientes no pueden ser negativos.

**OLS:** mínimos cuadrados ordinarios: regresión que minimiza la suma de los errores al cuadrado.

**P50 y P80:** percentiles de los futuros simulados; el costo real supera el P50 la mitad de las veces y el P80 dos de cada diez.

**Residuo:** diferencia entre el precio real y el que predice el modelo.

**Ruido blanco:** serie sin patrón ni memoria; es lo que queda cuando el modelo ya capturó toda la estructura.

**VIF:** factor de inflación de varianza; mide qué tanto se relacionan los insumos entre sí (multicolinealidad).

**Resumen**

La constructora necesita anticipar el costo de dos equipos críticos cuyo precio ha mostrado desviaciones presupuestales. A partir de 13 años de datos diarios (ene-2010 a ago-2023) se identificó qué materias primas determinan cada equipo, se proyectó su costo con intervalos de probabilidad y se construyó un agente de IA que permite consultar los resultados y combinarlos con noticias actuales del mercado.

- **Equipo 1 = 0.20 X + 0.80 Y.** La materia prima Y explica ~97% de su costo; **Z es ruido** para este equipo ($p = 0.999$).
- **Equipo 2 = 0.33 X + 0.33 Y + 0.33 Z.** Las tres son significativas, pero Z explica ~76% del costo.
- La relación es **estructural**: cinco métodos distintos coinciden, los pesos son estables desde 2013 y, entrenando solo con 2010-2019, el modelo predice 2020-2023 con **1.5% de error promedio** y sin sesgo.
- Comparadas contra series públicas, X coincide con el **petróleo Brent y Z con el aluminio**; Y es consistente con acero.
- Los precios de las materias primas se comportan como **caminata aleatoria**: ningún modelo (ARIMA, ETS, VAR) supera con claridad al pronóstico ingenuo. Dado esto, nos enfocamos en cuantificar la incertidumbre mediante una simulación Monte Carlo con bandas calibradas (la banda del 90% contuvo al valor real 90% de las veces).
- **Validación independiente:** los 8 meses reales de X posteriores al corte (sep-2023 a abr-2024) cayeron dentro de la banda pronosticada.
- **Horizonte recomendado: 6 meses, re-pronosticando cada mes.** Para presupuestar: P50 como base y P80 como presupuesto con contingencia.

## 1. Explicación del caso

Una empresa constructora planifica un proyecto con una ventana de ejecución definida, durante la cual debe abastecerse de forma continua de dos tipos de equipos críticos (Equipo 1 y Equipo 2). El costo de adquisición de estos equipos ha sido volátil y la empresa no ha logrado anticiparlo, lo que ha generado desviaciones presupuestales recurrentes. La gerencia sospecha que los precios dependen de la dinámica de ciertas materias primas, pero no tiene un modelo formal ni sabe cuáles son determinantes.

El problema de negocio se puede descomponer en cuatro preguntas:

1. **¿Qué explica el precio?** Identificar qué materias primas (X, Y, Z) determinan cada equipo y cuáles son ruido.
2. **¿Cuánto costará?** Proyectar el costo de cada equipo con un horizonte justificado y con su incertidumbre (intervalos), no solo un número.
3. **¿Cómo se usa?** Convertir el pronóstico en una herramienta de planeación financiera (presupuesto con contingencia, escenarios, evaluación de proveedores).
4. **¿Cómo se sostiene en el tiempo?** Un mecanismo reproducible (código, agente de IA y arquitectura en la nube) que se actualice con datos nuevos.

Los datos disponibles son cuatro archivos: tres series diarias de precios de materias primas (X, Y, Z) con formatos distintos y una tabla histórica (`historico_equipos.csv`) con las tres materias primas y los precios de los dos equipos, del 4-ene-2010 al 31-ago-2023 (3,530 días hábiles).

## 2. Supuestos

- **Datos confiables y comparables.** Los precios del histórico son correctos y están en las mismas unidades a lo largo del tiempo. Se verificó que el histórico coincide al 100% con los archivos crudos.
- **Relación lineal sin costo fijo.** El precio de cada equipo se forma como una combinación lineal de los insumos (una fórmula de costos), lo que es consistente con la práctica de fijar precios con fórmulas de ajuste por índice de materias primas. El supuesto se contrastó: la constante no resultó significativa.
- **Pesos no negativos.** Un insumo no puede abaratar un equipo al subir de precio; por eso el modelo se estima con mínimos cuadrados no negativos.
- **Estabilidad estructural.** El modelo de cada equipo no cambia en el horizonte de pronóstico (se verificó con ventanas móviles 2013-2023).
- **Frecuencia mensual para planear.** El presupuesto se planea por mes; además, el promedio mensual elimina el problema de que Y fue un precio semanal hasta 2017.
- **Eficiencia de mercado.** Los precios de las materias primas incorporan rápidamente la información disponible (Fama, 1970), por lo que su propia historia tiene poco poder predictivo; se contrasta empíricamente en la sección 5.
- **Identidad de X, Y y Z.** La prueba no revela qué materias primas son. Se identificaron en un análisis aparte, reproducible con series públicas (sección 4.2), que no entra al modelo: solo se usa para interpretar y buscar noticias. La identificación menos segura es la de Y como acero.
- **Fecha de corte.** El análisis se sitúa al cierre de los datos (ago-2023); el pronóstico cubre sep-2023 a ago-2024. El agente de IA, en cambio, consulta noticias de la fecha en que se usa.

## 3. Formas para resolver el caso y opción tomada

Para cada parte del problema se evaluaron varias alternativas. La Tabla 1 resume las opciones y la elegida.

**Tabla 1.** *Alternativas de solución evaluadas y opción tomada*

| Parte del problema | Alternativas consideradas | Opción tomada y razón |
|---|---|---|
| Relación insumos - equipo | Correlaciones; regresión en niveles; regresión en cambios; modelos no lineales (árboles, redes); selección automática (Lasso) | **Triangulación de 5 métodos** (OLS con errores HAC, cointegración, NNLS, elasticidades, Lasso). Un modelo lineal interpretable basta: $R^2 >$ 0.99 y residuo de ruido blanco; un modelo no lineal no tendría estructura adicional que capturar. |
| Pronóstico de insumos | Ingenuo (caminata aleatoria); ARIMA; suavizamiento exponencial (ETS); VAR multivariado; ML (XGBoost, LSTM) | **Comparación por backtesting** de origen móvil. Se eligió la caminata aleatoria por simplicidad, ya que ningún modelo complejo logró superarla. ML no se justifica con ~160 observaciones mensuales y una serie sin señal predecible. |
| Incertidumbre | Intervalos analíticos (normales); bootstrap simple; bootstrap por bloques; modelos GARCH | **Monte Carlo con bootstrap por bloques** de cambios históricos conjuntos (conserva correlación entre insumos y colas gordas), **calibrado** con backtesting. |
| Pronóstico de equipos | Modelar cada equipo por separado; modelar insumos y aplicar el modelo | **Insumos + modelo**: es coherente con la relación encontrada, permite escenarios por insumo y explica de dónde viene el riesgo. |
| Presentación (agente) | Chatbot con framework (LangChain); asistente sin herramientas; agente propio | **Agente propio desde cero** (ciclo, herramientas y memoria programados), con Gemini como modelo de lenguaje intercambiable y modo de |

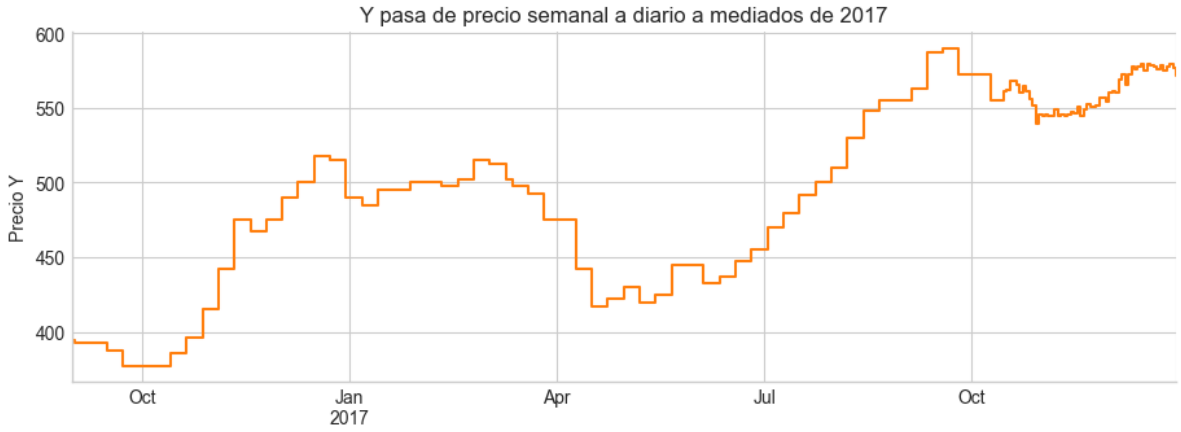
El flujo de trabajo completo es reproducible: tres notebooks en orden (01 limpieza y calidad, 02 relación, 03 pronóstico) que usan módulos Python reutilizables en `src/`, y una aplicación del agente en `agente/`.

## 4. Resultados del análisis de los datos y los modelos

### 4.1 Calidad de los datos

Cada archivo crudo trae un formato distinto (separadores, coma decimal, orden de columnas y de fechas), lo que se resolvió con funciones de carga específicas. El histórico coincide al 100% con los crudos en las 3,530 fechas. No hay nulos ni precios no positivos. El hallazgo de calidad más importante es que **Y fue un precio semanal hasta mediados de 2017** y diario después (Figura 1): **2,815 días** de Y repiten exactamente el precio del día anterior (~80% de los días antes de 2017). Esto vuelve engañoso cualquier análisis de cambios diarios con Y antes de 2017, por lo que la relación y el pronóstico se trabajaron en promedios mensuales. Además, Y mantuvo el mismo precio **70 días hábiles seguidos** (nov-2006 a feb-2007), lo que sugiere un periodo rellenado por la fuente; queda fuera del periodo de análisis, que inicia en 2010. Los saltos diarios mayores a 10% corresponden a eventos reales de mercado (p. ej., el colapso del petróleo en abril de 2020) y se conservaron, ya que eliminarlos subestimaría el riesgo.

**Figura 1.** *La serie Y pasa de precio semanal a diario a mediados de 2017*




### 4.2 ¿Qué materias primas son X, Y y Z?

La prueba no indica qué materias primas son X, Y y Z. El modelo no lo necesita, pero el agente sí, para buscar noticias del mercado correcto. La identificación no usa conocimiento previo del mercado: compara cada serie, mes a mes, contra listas de precios públicas y gratuitas, guardadas en data/external/ (notebook 01, sección 4), con dos medidas: la correlación de los cambios mensuales y la proporción entre niveles (1 = mismo precio). Primero se barrió el catálogo de 46 materias primas del Fondo Monetario Internacional (Federal Reserve Bank of St. Louis, s.f.-f). X coincide con el petróleo Brent (Federal Reserve Bank of St. Louis, s.f.-a) y Z con el aluminio (Federal Reserve Bank of St. Louis, s.f.-b): correlaciones de 0.995 y 0.997 y proporción de 0.999, muy por arriba del siguiente candidato (petróleo Dubái, 0.975; zinc, 0.65). Además, X no es WTI, que llegó a -36.98 USD el 20-abr-2020 (Federal Reserve Bank of St. Louis, s.f.-c), cuando X valía 25.57, y en algunos días difiere hasta 11 USD del Brent spot (Federal Reserve Bank of St. Louis, s.f.-d), lo que sugiere

que X es el precio de los futuros. Y no coincide con ninguna serie del catálogo (máximo 0.52), que no incluye acero; contra el futuro de acero laminado en caliente de Shanghái convertido a dólares (Shanghai Futures Exchange, s.f.; Federal Reserve Bank of St. Louis, s.f.-e) tiene el mismo nivel (0.96) y una correlación de 0.84, mayor que la de la varilla de acero (0.76; Shanghai Futures Exchange, s.f.). Así, **X es petróleo Brent y Z es aluminio; Y es consistente con acero de China**, aunque su serie exacta no se identificó con fuentes gratuitas. Son insumos coherentes con equipos de construcción.

### 4.3 Relación entre materias primas y equipos

Las series en niveles no son estacionarias según la prueba de Dickey y Fuller (1979), por lo que una regresión en niveles podría ser espuria. Sin embargo, la prueba de cointegración de Engle y Granger (1987) rechaza ampliamente la ausencia de cointegración ($p < 0.001$) para ambos equipos: el precio del equipo y su combinación de insumos mantienen un equilibrio de largo plazo, lo que valida la regresión en niveles. Los errores estándar se estimaron con el estimador robusto de Newey y West (1987) para corregir la autocorrelación.

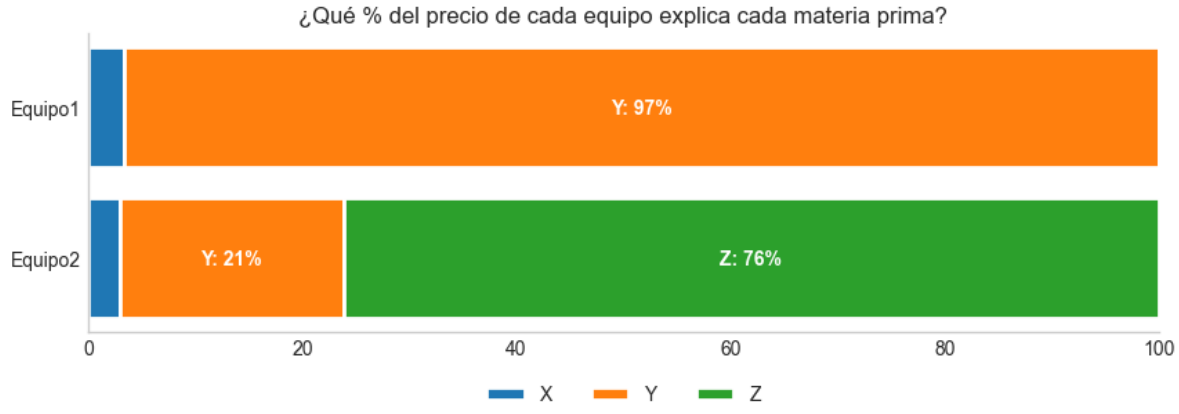
**Tabla 2.** *Pesos estimados de cada materia prima (mínimos cuadrados no negativos, datos diarios 2010-2023)*

| Equipo | X | Y | Z | $R^2$ | Determinante principal | Ruido |
|---|---|---|---|---|---|---|
| Equipo 1 | 0.198 | 0.800 | 0.000 | 0.995 | Y (~97% del costo) | Z (p = 0.999) |
| Equipo 2 | 0.335 | 0.336 | 0.332 | 0.992 | Z (~76%), Y (~21%) | Ninguno |

*Nota.* La constante no fue significativa en ningún equipo ($p > 0.4$). Factores de inflación de varianza entre 1.3 y 3.6: sin multicolinealidad problemática.

Un coeficiente grande no implica importancia económica: hay que multiplicarlo por el nivel de precio del insumo. Por eso se calculó la **participación en el costo** (Figura 2). Aunque X es estadísticamente significativo, explica solo ~3% del costo de cada equipo.

**Figura 2.** *Participación de cada materia prima en el precio de cada equipo*




La conclusión se confirmó con otros dos enfoques sobre **cambios mensuales** (que eliminan la tendencia): las elasticidades (Equipo 1: 0.97 respecto a Y; Equipo 2: 0.76 respecto a Z y 0.20 respecto a Y) coinciden con las participaciones en el costo, y la regresión Lasso (Tibshirani, 1996) con validación cruzada temporal lleva el coeficiente de Z a exactamente cero en el Equipo 1, descartándolo como ruido.

### 4.4 Estabilidad y validación fuera de muestra

Los pesos re-estimados en ventanas móviles de 36 meses se mantienen prácticamente constantes desde 2013 (Figura 3), lo que indica una relación estructural y no casual. Para

medir el poder predictivo real se entrenaron los pesos solo con 2010-2019 y se predijo 2020-2023, periodo de alta volatilidad (pandemia y guerra en Ucrania): el error absoluto porcentual medio fue de **1.5% en ambos equipos, sin sesgo** (Figura 4).

**Figura 3.** *Pesos estimados en ventanas móviles de 36 meses*

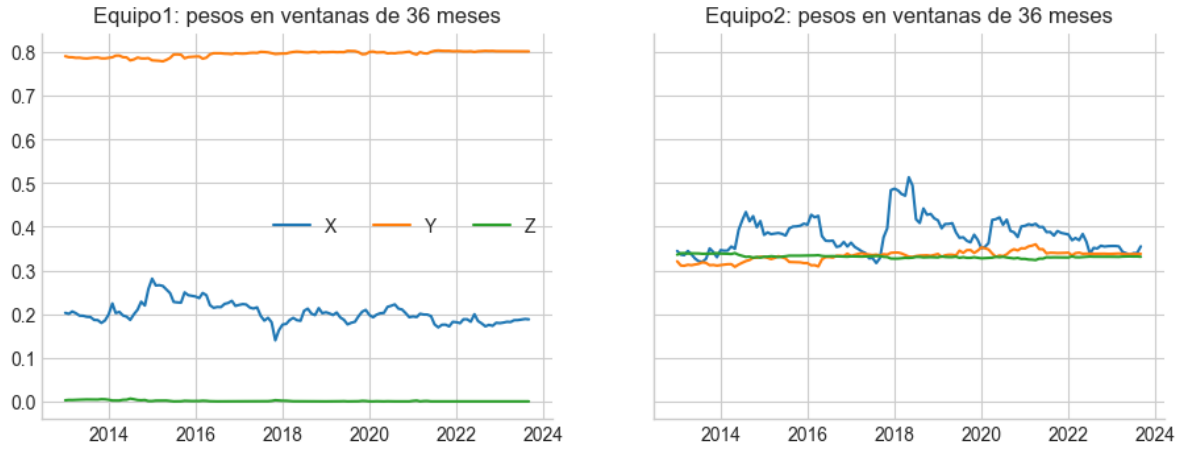



**Figura 4.** *Precio real vs. predicho con pesos entrenados en 2010-2019*




*Nota.* El modelo usa los precios observados de los insumos; el error refleja solo la relación insumo-equipo.

Una evidencia adicional, sencilla e independiente de la estadística, proviene de los saltos diarios: en los **8 días** en que un equipo cambió más de ~10%, su insumo principal se movió **el mismo día y en la misma dirección** (Tabla 3), mientras que Z, que no forma parte del modelo del Equipo 1, apenas se movió (máximo 1.3%). En dos saltos del Equipo 1, Y se movió menos (-6.0% y -4.7%); la diferencia es atribuible al ruido propio del equipo (sección 4.5), pero la dirección coincide.

**Tabla 3.** *Días con cambios mayores a ~10% en el precio de un equipo y cambio de las materias primas el mismo día*

| Equipo | Fecha | Cambio del equipo | X | Y | Z |
|---|---|---|---|---|---|
| Equipo 1 | 2015-07-10 | -11.0% | +0.2% | -6.0% | +0.2% |
| Equipo 1 | 2016-03-18 | +10.6% | -0.8% | +13.0% | -0.4% |

| | | | | | |
|---|---|---|---|---|---|
| Equipo 1 | 2016-04-15 | +14.2% | -1.7% | +11.9% | -0.9% |
| Equipo 1 | 2020-12-28 | -9.9% | -0.8% | -4.7% | -1.1% |
| Equipo 1 | 2021-04-08 | +11.7% | +0.1% | +11.4% | +1.3% |
| Equipo 1 | 2022-07-15 | -9.6% | +2.1% | -8.2% | -0.4% |
| Equipo 2 | 2018-04-24 | -12.5% | -1.1% | -0.5% | -9.4% |
| Equipo 2 | 2022-03-08 | -10.8% | +3.9% | +0.0% | -12.1% |

*Nota.* Salto: cambio logarítmico diario mayor a 0.10 en valor absoluto. Insumo principal: Y para el Equipo 1 y Z para el Equipo 2.

### 4.5 Diagnóstico de residuos

El residuo diario es de ±1.7% (desviación estándar), centrado en cero, estacionario y sin autocorrelación según la prueba de Ljung y Box (1978) ($p > 0.05$). En promedio mensual el ruido cae a ±0.3-0.4%. Al ser ruido blanco, no queda estructura por modelar con estos datos: **precio del equipo = modelo de insumos + ruido pequeño e impredecible** (probablemente negociación, logística o margen del proveedor).

Este resultado tiene un uso práctico adicional que pide el caso: **evaluar proveedores de forma objetiva**. Con el modelo y el tamaño del ruido se obtiene un precio justo con una banda de tolerancia del 95%; una cotización por encima de la banda es atípicamente cara. Por ejemplo, con los insumos de ago-2023 el precio estimado del Equipo 1 es de ~462 (banda 446-478), por lo que una cotización de 520 está 12.5% por encima del mercado.

## 5. Proyección de costos y horizonte de predicción

### 5.1 Selección del modelo de pronóstico

Dado que el precio del equipo es un modelo de insumos, pronosticar los equipos equivale a pronosticar X, Y y Z y aplicar el modelo. Se compararon cuatro modelos con un backtest de origen móvil: desde ene-2016, cada mes se entrenó con la historia disponible y se pronosticaron los 12 meses siguientes. Los modelos fueron la caminata aleatoria (ingenuo), ARIMA(1,1,0) (Box et al., 2015), suavizamiento exponencial con tendencia amortiguada (Hyndman & Athanasopoulos, 2021) y un VAR(1) que modela los tres insumos juntos (Sims, 1980).

**Tabla 4.** *Error absoluto porcentual medio (%) del backtest 2016-2023, por insumo y horizonte (meses)*

| Insumo | Meses | Ingenuo | ARIMA(1,1,0) | ETS amortiguado | VAR(1) |
|---|---|---|---|---|---|
| X | 1 | 7.3 | 7.1 | 7.6 | 6.7 |
| X | 6 | 21.1 | 21.1 | 22.1 | 21.0 |
| X | 12 | 30.3 | 30.5 | 32.8 | 31.0 |
| Y | 1 | 5.1 | 5.0 | 5.4 | 4.9 |
| Y | 6 | 15.4 | 16.3 | 18.3 | 17.7 |
| Y | 12 | 24.5 | 24.1 | 26.4 | 26.6 |
| Z | 1 | 3.6 | 3.5 | 3.6 | 3.6 |
| Z | 6 | 12.1 | 12.1 | 12.6 | 12.5 |
| Z | 12 | 19.0 | 18.9 | 20.4 | 20.2 |

**Ningún modelo supera con claridad al ingenuo.** A un mes, ARIMA y VAR mejoran unas décimas porque aprovechan la inercia que produce promediar el mes; a partir de tres meses las diferencias son mínimas o favorecen al ingenuo. Esto concuerda con el comportamiento habitual de las materias primas (Fama, 1970), donde las series históricas por sí solas tienen

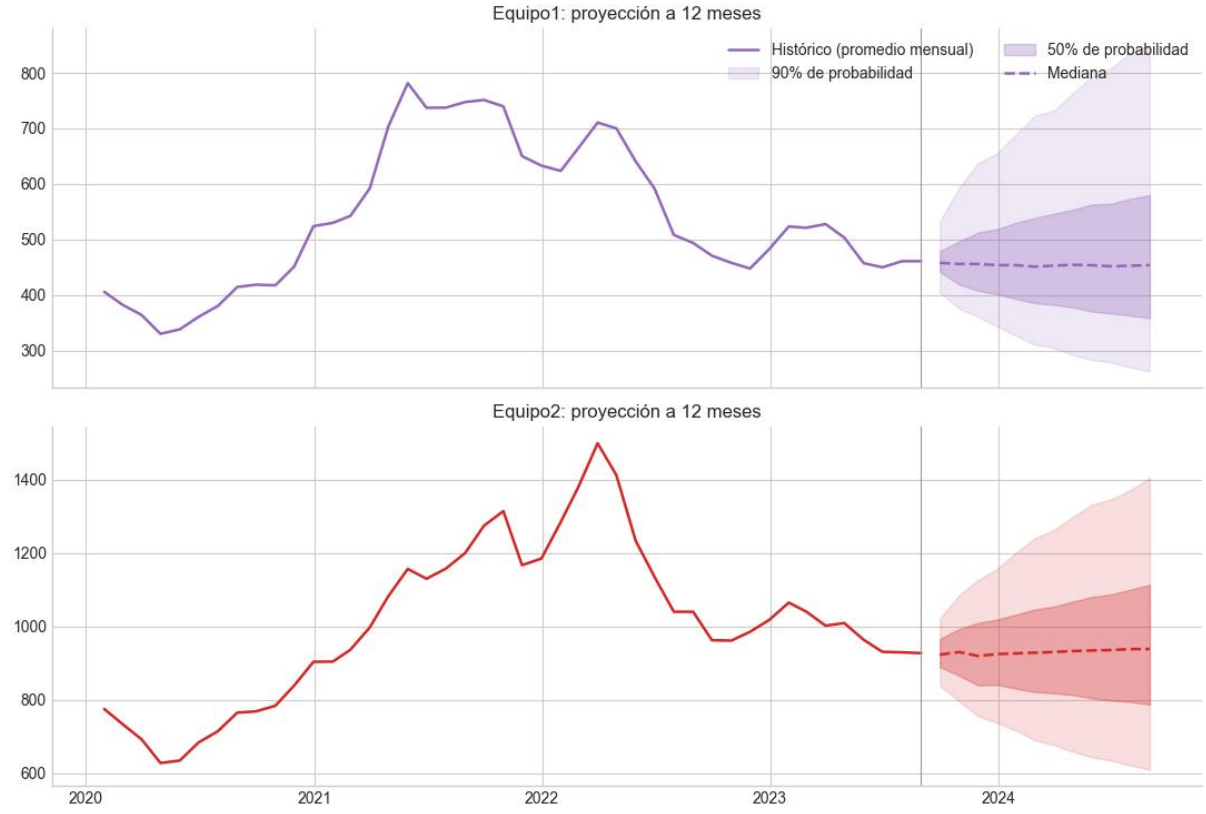
bajo poder predictivo a mediano plazo. Por parsimonia, el centro del pronóstico es la caminata aleatoria y el esfuerzo se concentra en medir bien la incertidumbre.

### 5.2 Incertidumbre: simulación Monte Carlo calibrada

Se simularon 10,000 trayectorias futuras de X, Y y Z remuestreando cambios mensuales históricos (2010-2023) en bloques de tres meses, tomando los tres insumos del mismo mes juntos. El bootstrap por bloques (Efron & Tibshirani, 1993) conserva la correlación entre insumos, la inercia de corto plazo y las colas gordas reales sin suponer normalidad. A cada trayectoria se le aplica el modelo de cada equipo y su ruido propio, lo que da la distribución completa del costo.

Para verificar la calibración de los intervalos, se evaluó que la banda del 90% contuviera al valor observado el 90% de las ocasiones en el backtest. Con los cambios históricos tal cual, la cobertura real en el backtest fue de solo ~78%, porque 2016-2023 fue más volátil que el promedio. Se calibró un factor de escala de los choques: con 1.4 la banda del 90% cubrió el 90% de los casos y la del 50% el 48%.

**Figura 5.** *Proyección a 12 meses del costo de cada equipo con bandas de probabilidad*

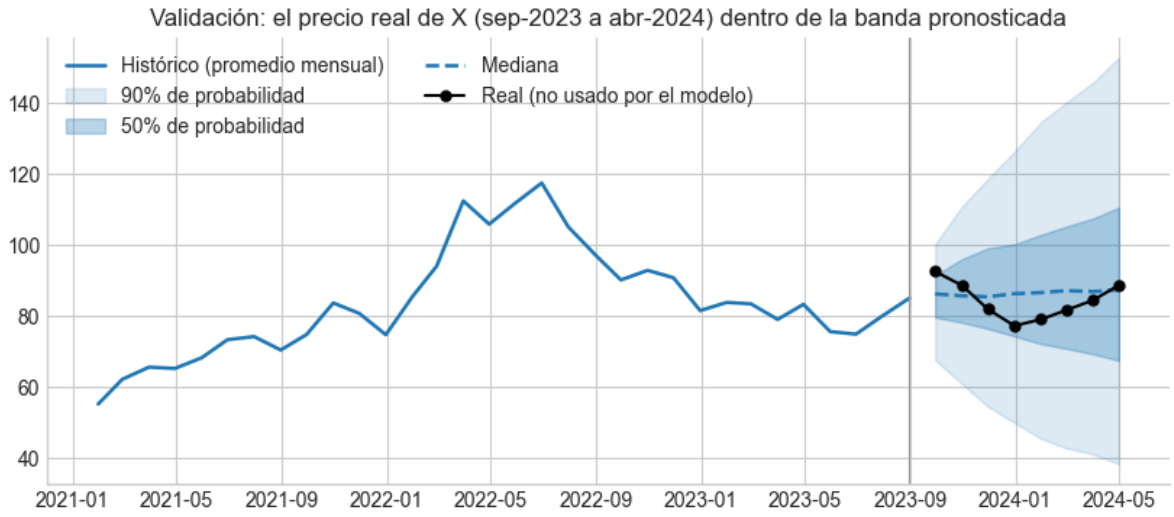



*Nota.* Bandas: 50% (P25-P75) y 90% (P5-P95) de probabilidad. Línea discontinua: mediana (P50).

### 5.3 Validación con datos posteriores al corte (2023-2024)

El archivo X.csv contiene precios hasta abril de 2024, posteriores al corte de los equipos. Los 8 meses reales de X (sep-2023 a abr-2024) cayeron todos dentro de la banda del 90% pronosticada, y 7 de 8 dentro de la banda del 50% (Figura 6). Esto permite validar las bandas pronosticadas con observaciones reales posteriores al cierre de la base.

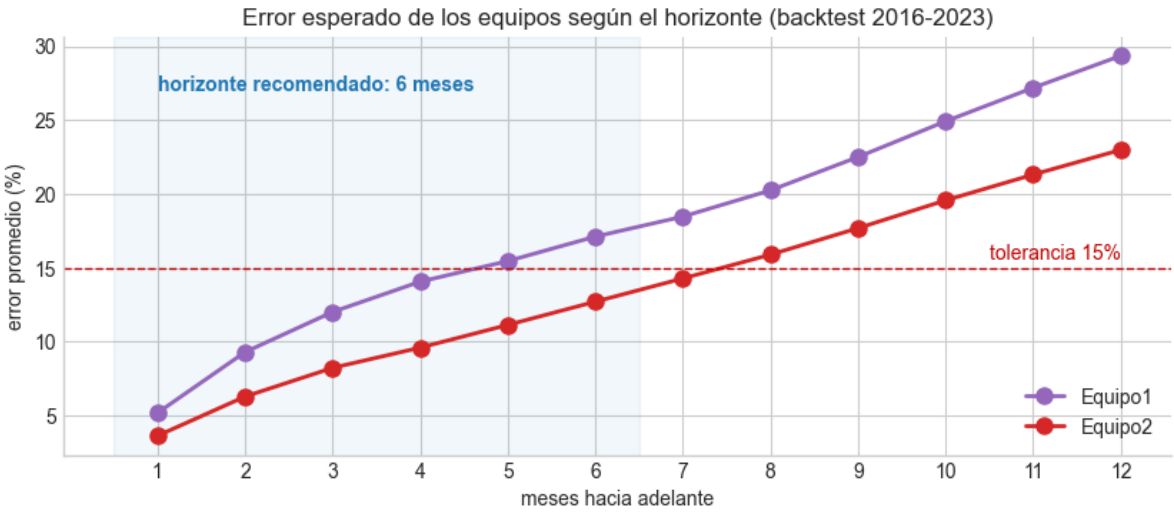
**Figura 6.** *Precio real de X después del corte frente a la banda pronosticada*




## 5.4 Horizonte de predicción

El horizonte se eligió con un criterio de negocio: proyectar mientras el error esperado sea menor a 15%, un nivel típico de contingencia en presupuestos de proyectos (Project Management Institute [PMI], 2021). El Equipo 1 cruza ese umbral alrededor del mes 5 y el Equipo 2 alrededor del mes 8, porque su mezcla de tres insumos diversifica el riesgo (Figura 7).

**Figura 7.** *Error esperado de cada equipo según los meses de anticipación*




**Horizonte recomendado: 6 meses, re-pronosticando cada mes con el dato nuevo.** Los meses 7 a 12 se reportan solo como referencia de riesgo. Más allá de ese horizonte, la herramienta adecuada no es un pronóstico más complejo sino la **cobertura del riesgo**: contratos a precio fijo, cláusulas de ajuste por índice o coberturas con futuros de las materias primas.

## 5.5 Del pronóstico al presupuesto

Se propone presupuestar con el percentil 50 (P50) como escenario base y el percentil 80 (P80) como presupuesto con contingencia; la diferencia es la reserva por volatilidad, en línea con la práctica de reservas de contingencia en gestión de proyectos (PMI, 2021).

**Tabla 5.** *Precio unitario proyectado por mes y reserva de contingencia (horizonte recomendado de 6 meses)*

| Equipo | Mes | P50 (base) | P80 (contingencia) | P90 (conservador) | Reserva P80 vs P50 |
|---|---|---|---|---|---|
| Equipo 1 | Sep-2023 | 458.1 | 488.3 | 513.3 | 6.6% |
| Equipo 1 | Oct-2023 | 455.9 | 510.4 | 549.3 | 11.9% |
| Equipo 1 | Nov-2023 | 456.0 | 528.8 | 601.3 | 16.0% |
| Equipo 1 | Dec-2023 | 453.9 | 539.3 | 601.4 | 18.8% |
| Equipo 1 | Jan-2024 | 453.8 | 552.3 | 623.5 | 21.7% |
| Equipo 1 | Feb-2024 | 451.1 | 566.8 | 640.7 | 25.6% |
| Equipo 2 | Sep-2023 | 923.4 | 974.6 | 1,003.6 | 5.5% |
| Equipo 2 | Oct-2023 | 930.7 | 1,004.4 | 1,051.7 | 7.9% |
| Equipo 2 | Nov-2023 | 920.0 | 1,030.4 | 1,089.3 | 12.0% |
| Equipo 2 | Dec-2023 | 925.0 | 1,045.1 | 1,110.4 | 13.0% |
| Equipo 2 | Jan-2024 | 927.1 | 1,064.0 | 1,136.2 | 14.8% |
| Equipo 2 | Feb-2024 | 928.8 | 1,079.0 | 1,166.6 | 16.2% |

*Nota.* Precios en las mismas unidades que los datos de origen. El Equipo 1 requiere más reserva porque depende casi de un solo insumo.

### 5.6 Escenarios de estrés

**Tabla 6.** *Impacto de choques en las materias primas sobre el precio de los equipos (base: ago-2023)*

| Escenario | Equipo 1 | Cambio | Equipo 2 | Cambio |
|---|---|---|---|---|
| Actual (ago-2023) | 462.1 | +0.0% | 924.3 | +0.0% |
| Y +20% | 551.1 | +19.3% | 961.7 | +4.0% |
| Z +20% | 462.1 | +0.0% | 1,066.2 | +15.3% |
| X +20% | 465.4 | +0.7% | 930.0 | +0.6% |
| Peor alza 6m de Y (May-2021, +74%) | 790.0 | +71.0% | 1,061.9 | +14.9% |
| Peor alza 6m de Z (Nov-2020, +32%) | 462.1 | +0.0% | 1,153.1 | +24.8% |
| Tormenta: X, Y y Z +20% | 554.5 | +20.0% | 1,109.2 | +20.0% |

Un alza de 20% en Y sube el Equipo 1 casi 20%, pero el Equipo 2 solo 4%. Si se repitiera el peor episodio histórico de Y (alza de 74% en seis meses hasta mayo de 2021), el Equipo 1 subiría ~71%: ese es el riesgo de cola que conviene cubrir contractualmente.

## 6. Presentación de resultados en un agente de IA

### 6.1 Sistema de IA convencional frente a agente de IA

Un **sistema de IA convencional** es un modelo que transforma una entrada en una salida: predice, clasifica o genera. Es pasivo, hace una sola tarea cuando se le pide y no decide qué hacer después. En este caso, el modelo de pronóstico es un sistema convencional: recibe datos y devuelve bandas de precio.

Un **agente de IA** es un sistema que percibe su entorno y actúa sobre él para alcanzar un objetivo (Russell & Norvig, 2021). Se caracteriza por su autonomía, reactividad, proactividad y habilidad social. En los agentes basados en modelos de lenguaje, el modelo razona y decide qué acciones tomar, intercalando razonamiento y uso de herramientas (Yao et al., 2023), y puede aprender a invocar herramientas externas para obtener información que no tiene. Los conceptos clave son:

**Tabla 7.** *Conceptos de un agente de IA y cómo se implementan en esta solución*

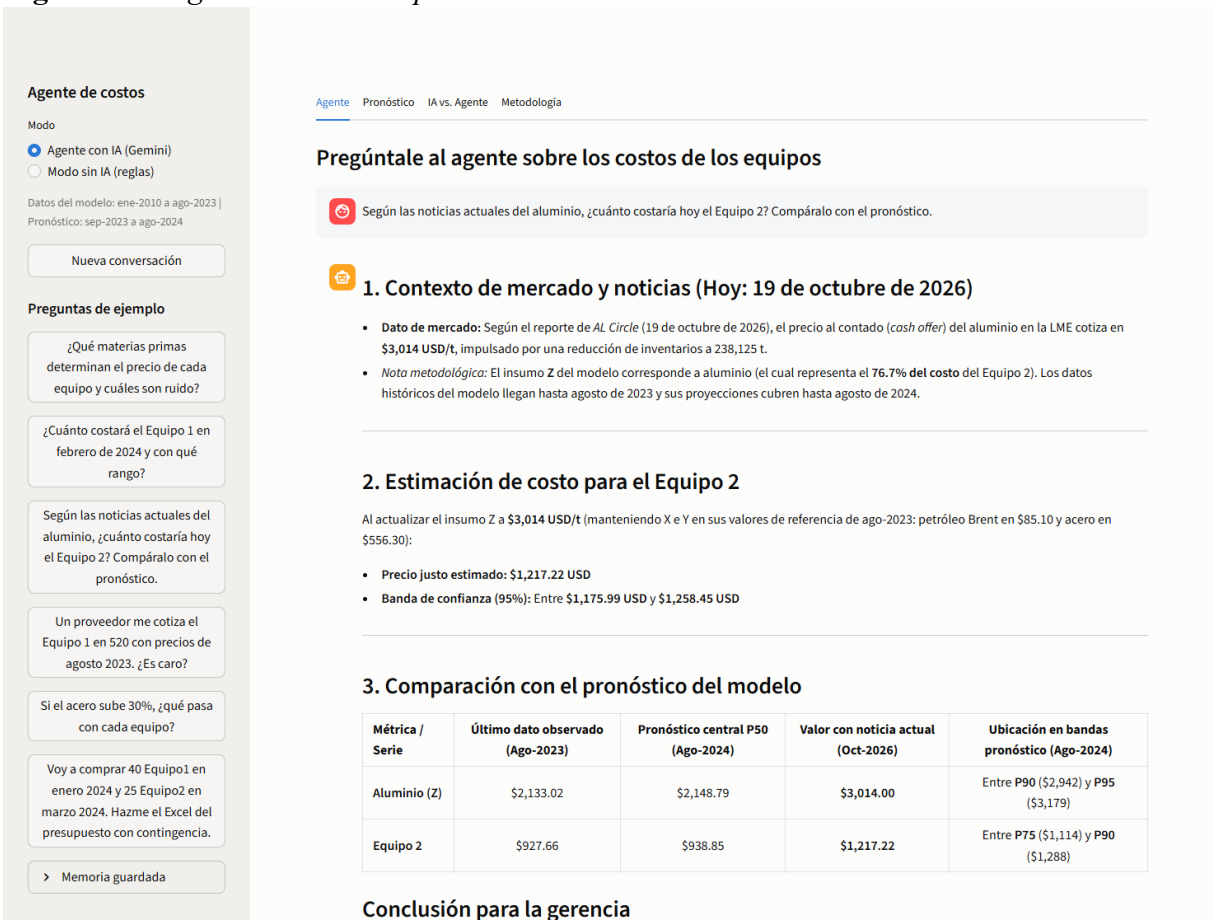
| Concepto | Qué significa | Implementación en este agente |
|---|---|---|
| Autonomía | Decide qué pasos dar y en qué orden para cumplir el objetivo | Ciclo propio (percibir, decidir, actuar y observar), con un máximo de pasos como freno de seguridad |
| Uso de herramientas | Invoca funciones externas para obtener datos o calcular | 9 herramientas: resumen del modelo, pronóstico, presupuesto, escenarios, precio justo, ubicación en bandas, noticias, memoria y reporte |
| Memoria | Recuerda el contexto (corto plazo) y conocimiento entre sesiones (largo plazo) | Historial de la conversación + notas persistentes en un archivo JSON |
| Capacidad de acción | Produce efectos en el entorno, no solo texto | Genera un Excel de presupuesto descargable y guarda decisiones del usuario |
| Percepción del entorno | Incorpora información nueva del mundo | Consulta titulares recientes de Google News sobre cada insumo |

## 6.2 Diseño del agente

El agente se programó **desde cero, sin frameworks de agentes**, para controlar y poder explicar cada paso. El modelo de lenguaje (Gemini, en su capa gratuita) se usa solo como "cerebro de lenguaje": recibe las instrucciones, la memoria y el catálogo de herramientas descrito con esquemas JSON, y decide si responder o pedir herramientas mediante llamadas a funciones (Google, s.f.). La ejecución automática del proveedor está desactivada: el ciclo, la ejecución de herramientas y el manejo de errores son código propio. El modelo es intercambiable (por ejemplo, por Azure OpenAI) cambiando un adaptador.

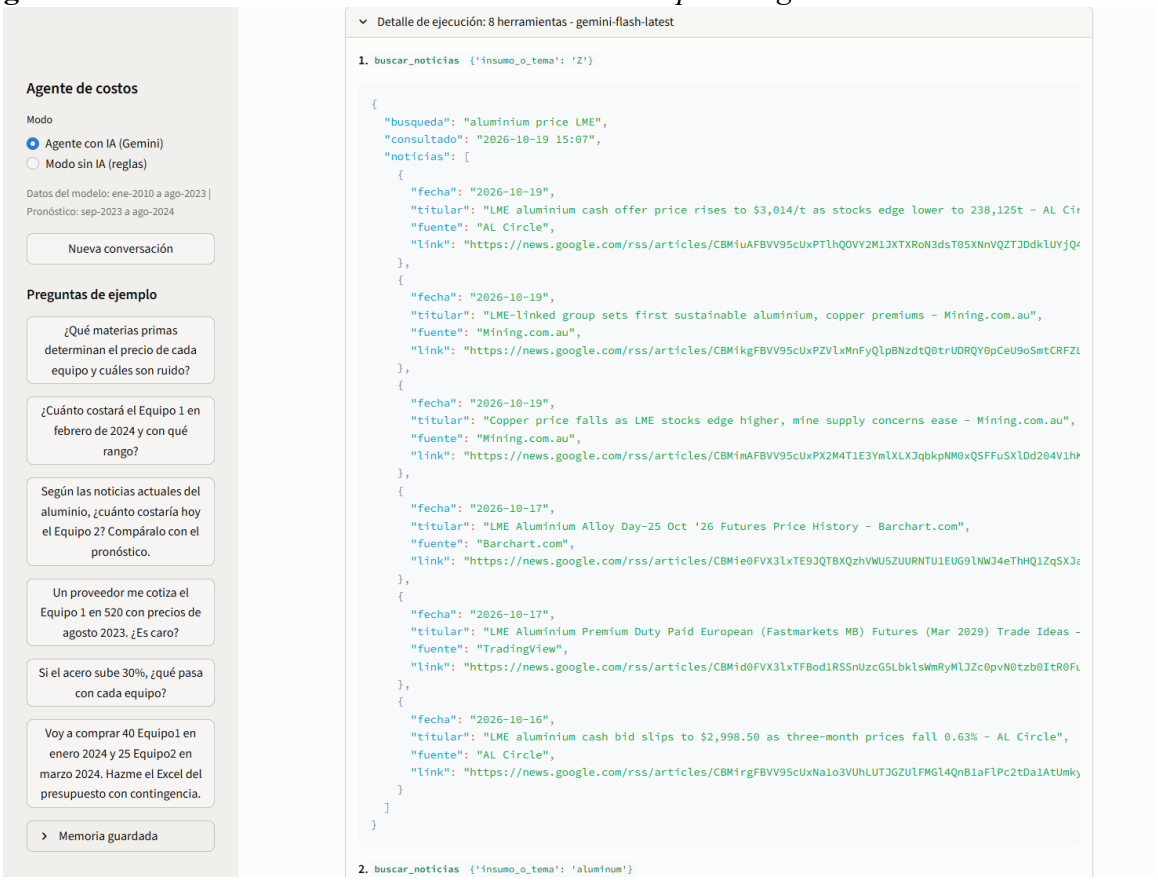
Reglas de diseño relevantes: todo número sale de una herramienta (el agente no inventa cifras); se separa explícitamente "lo que dice el modelo" de "lo que dicen las noticias" y se aclara la diferencia de fechas; ante saturación de la cuota gratuita el agente reintenta y cambia a un modelo más ligero; y si la IA no está disponible, un **modo de respaldo por reglas** responde con las mismas herramientas.

**Figura 8.** *El agente combina el pronóstico con noticias actuales del mercado*




*Nota.* El agente buscó noticias del aluminio, extrajo el precio actual (3,014 USD/t), lo aplicó al modelo del Equipo 2 y lo ubicó dentro de las bandas pronosticadas.

**Figura 9.** *Traza auditable de las herramientas usadas por el agente*



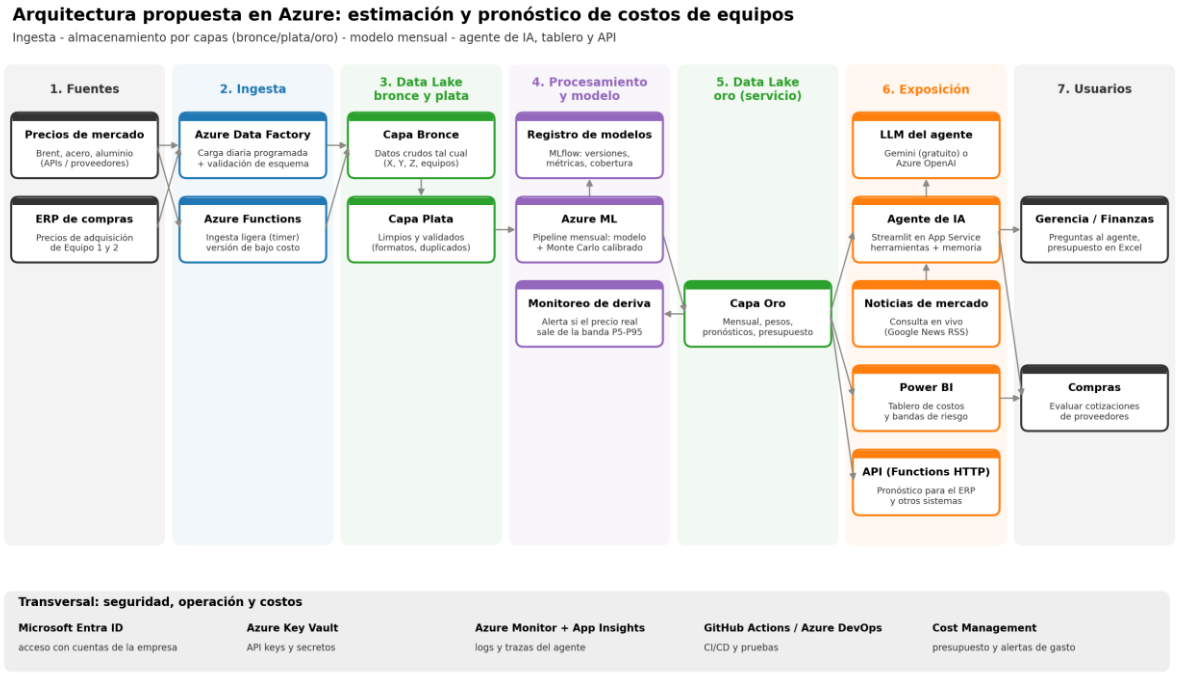

*Nota.* Cada respuesta muestra qué herramientas eligió el agente, con qué argumentos y qué resultados obtuvo.

La aplicación (Streamlit) incluye además un pronóstico interactivo, la explicación de la diferencia entre modelo y agente con el diagrama del ciclo, y un resumen de la metodología.

## 7. Arquitectura propuesta en la nube (Azure)

La arquitectura sigue los pilares del Azure Well-Architected Framework (confiabilidad, seguridad, optimización de costos, excelencia operativa y eficiencia) (Microsoft, s.f.-a) y organiza los datos en capas bronce, plata y oro, un patrón de lakehouse que separa datos crudos, limpios y listos para consumo (Microsoft, s.f.-b).

**Figura 10.** *Arquitectura propuesta en Azure*




*Nota.* Archivo editable en draw.io: arquitectura/arquitectura_azure.drawio.

**Tabla 8.** *Componentes de la arquitectura y su función*

| Etapa | Servicio de Azure | Función en la solución |
|---|---|---|
| Ingesta | Azure Data Factory / Azure Functions (timer) | Carga diaria de precios de mercado y de compras del ERP, con validación de esquema |
| Almacenamiento | Azure Data Lake Storage Gen2 (bronce, plata, oro) | Crudos inmutables, datos limpios y resultados (modelos, pronósticos, presupuesto) |
| Procesamiento | Azure Machine Learning (pipeline mensual) + MLflow | Re-estima el modelo, corre el Monte Carlo calibrado y registra versiones y métricas |
| Monitoreo del modelo | Alerta de deriva | Avisa si el precio real sale de la banda P5-P95 o si los pesos cambian |
| Exposición | App Service / Container Apps; Power BI; Functions HTTP | Agente de IA, tablero de costos y API para el ERP |
| Transversal | Entra ID, Key Vault, Monitor/App Insights, CI/CD, Cost Management | Acceso, secretos, trazas del agente, despliegue automatizado y control de gasto |

Se proponen dos niveles. Un **MVP de bajo costo** (Blob/Data Lake, Functions de consumo, App Service básico y Key Vault) tiene un costo estimado de unos 15 USD mensuales; la versión **empresarial** agrega Data Factory, Azure Machine Learning, Power BI y Entra ID. Los costos deben confirmarse con la calculadora de precios de Azure (Microsoft, s.f.-c).

## 8. Futuros ajustes o mejoras

- **Datos reales del proyecto:** cantidades y fechas de compra para convertir el pronóstico unitario en flujo de caja del proyecto, y precios por proveedor para un ranking de proveedores.
- **Variables exógenas:** tipo de cambio, inflación, fletes y curvas de futuros de acero, aluminio y Brent, que incorporan la expectativa del mercado y suelen superar a la caminata aleatoria en horizontes medios.
- **Actualización automática:** conectar fuentes de precios diarias para que el modelo se re-entrene cada mes y el agente use precios actuales en lugar de solo titulares.

- **Monitoreo de deriva:** alertas cuando el modelo cambie (p. ej., un proveedor modifique materiales) o el precio salga de la banda; re-calibración periódica de la escala de los choques.
- **Optimización de compras:** decidir cuándo adelantar compras o fijar precio con contrato, minimizando costo esperado y riesgo (p. ej., valor en riesgo del presupuesto).
- **Agente:** evaluación sistemática de sus respuestas, guardrails de costos y despliegue con autenticación de la empresa; búsqueda de noticias con lectura del artículo completo y análisis de sentimiento.

## 9. Apreciaciones y comentarios del caso

Como conclusión del ejercicio, destaco tres puntos. Primero, la revisión previa de los datos evitó sesgos por el cambio de frecuencia de Y en 2017. Segundo, la validación con cointegración y pruebas fuera de muestra fue necesaria para descartar regresiones espurias. Por último, dada la alta volatilidad de las materias primas, resulta más útil para la constructora trabajar con bandas de probabilidad y reservas de contingencia (P80) que depender únicamente de un pronóstico puntual.

**Referencias**


Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time series analysis: Forecasting and control* (5.ª ed.). Wiley.

Dickey, D. A., & Fuller, W. A. (1979). Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association, 74*(366), 427-431. https://doi.org/10.1080/01621459.1979.10482531

Efron, B., & Tibshirani, R. J. (1993). *An introduction to the bootstrap*. Chapman & Hall/CRC.

Engle, R. F., & Granger, C. W. J. (1987). Co-integration and error correction: Representation, estimation, and testing. *Econometrica, 55*(2), 251-276. https://doi.org/10.2307/1913236

Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. *The Journal of Finance, 25*(2), 383-417. https://doi.org/10.2307/2325486

Federal Reserve Bank of St. Louis. (s.f.-a). *Global price of Brent Crude (POILBREUSDM)* [Datos del Fondo Monetario Internacional]. FRED. Recuperado el 19 de octubre de 2026, de https://fred.stlouisfed.org/series/POILBREUSDM

Federal Reserve Bank of St. Louis. (s.f.-b). *Global price of Aluminum (PALUMUSDM)* [Datos del Fondo Monetario Internacional]. FRED. Recuperado el 19 de octubre de 2026, de https://fred.stlouisfed.org/series/PALUMUSDM

Federal Reserve Bank of St. Louis. (s.f.-c). *Crude oil prices: West Texas Intermediate (WTI) - Cushing, Oklahoma (DCOILWTICO)* [Datos de la U.S. Energy Information Administration]. FRED. Recuperado el 19 de octubre de 2026, de https://fred.stlouisfed.org/series/DCOILWTICO

Federal Reserve Bank of St. Louis. (s.f.-d). *Crude oil prices: Brent - Europe (DCOILBRENTEU)* [Datos de la U.S. Energy Information Administration]. FRED. Recuperado el 19 de octubre de 2026, de https://fred.stlouisfed.org/series/DCOILBRENTEU

Federal Reserve Bank of St. Louis. (s.f.-e). *China / U.S. foreign exchange rate (DEXCHUS)* [Datos de la Reserva Federal, H.10]. FRED. Recuperado el 19 de octubre de 2026, de https://fred.stlouisfed.org/series/DEXCHUS

Federal Reserve Bank of St. Louis. (s.f.-f). *Precios globales de 46 materias primas, catálogo del Fondo Monetario Internacional* [IDs en data/external/fred_catalogo_fmi_series.csv]. FRED. Recuperado el 19 de octubre de 2026, de https://fred.stlouisfed.org/

Google. (s.f.). *Function calling with the Gemini API*. Google AI for Developers. Recuperado el 15 de octubre de 2026, de https://ai.google.dev/gemini-api/docs/function-calling

Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3.ª ed.). OTexts. https://otexts.com/fpp3/

Ljung, G. M., & Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika, 65*(2), 297-303. https://doi.org/10.1093/biomet/65.2.297

Microsoft. (s.f.-a). *Azure Well-Architected Framework*. Microsoft Learn. Recuperado el 15 de octubre de 2026, de https://learn.microsoft.com/es-es/azure/well-architected/

Microsoft. (s.f.-b). *What is the medallion lakehouse architecture?* Microsoft Learn. Recuperado el 15 de octubre de 2026, de https://learn.microsoft.com/es-es/azure/databricks/lakehouse/medallion

Microsoft. (s.f.-c). *Calculadora de precios de Azure*. Recuperado el 15 de octubre de 2026, de https://azure.microsoft.com/es-es/pricing/calculator/

Newey, W. K., & West, K. D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica, 55*(3), 703-708. https://doi.org/10.2307/1913610

Project Management Institute. (2021). *A guide to the project management body of knowledge (PMBOK guide)* (7.ª ed.). Project Management Institute.

Russell, S., & Norvig, P. (2021). *Artificial intelligence: A modern approach* (4.ª ed.). Pearson.

Shanghai Futures Exchange. (s.f.). *Hot rolled coil and steel rebar futures* [Datos históricos de cotización de los contratos continuos de acero laminado en caliente y varilla]. https://www.shfe.com.cn/

Sims, C. A. (1980). Macroeconomics and reality. *Econometrica, 48*(1), 1-48. https://doi.org/10.2307/1912017

Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B (Methodological), 58*(1), 267-288. https://doi.org/10.1111/j.2517-6161.1996.tb02080.x

Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., & Cao, Y. (2023). ReAct: Synergizing reasoning and acting in language models. *International Conference on Learning Representations*. https://arxiv.org/abs/2210.03629